

Du support de formation à l'e-learning, par intelligence artificielle

Conception et réalisation d'un système automatisé de génération de cours vidéo

● ——— Réalisé par · Hala Sadoumi

4ème année — Intelligence Artificielle & Data Science

Encadrante professionnelle · Mme Firdaous Bazhod
Encadrant pédagogique · M. Hamza Abouabid
S2M Casablanca · Année universitaire 2025 / 2026



Plan de la présentation

01 *Contexte & problématique*
Pourquoi ce projet

02 *S2M Casablanca*
L'organisme d'accueil

03 *Objectifs & solution*
Ce que le système doit faire

04 *Conception*
Cas d'utilisation, classes, activité, pipeline

05 *Les neuf étapes*
Le fonctionnement, étape par étape

06 *Technologies*
Les outils retenus et pourquoi

07 *Résultats & validation*
Ce que le système produit réellement

08 *Conclusion & perspectives*
Le bilan et la suite

Contexte & problématique

Support

– Analyse

– Scénarisation

– Voix

– Montage

– Sous-titres

– Publication

Une production manuelle longue, répétitive et difficile à reproduire à grande échelle.

Comment automatiser la transformation d'un support de formation en un cours e-learning complet, structuré et pédagogique ?

- — Le problème n'est pas de diffuser un cours — c'est de le produire.

LE CONTEXTE DU STAGE

S2M Casablanca

Monétique

Systèmes de paiement électronique

Édition logicielle

Solutions conçues et déployées

Moyens de paiement

Cartes et terminaux

Payment as a Service

Exploitation pour le client

● ———— Présence internationale — Maroc, Afrique, Moyen-Orient, Asie, Océanie

D É P A R T E M E N T D ' A C C U E I L

Ressources Humaines — Formation

Rendre les formations plus accessibles, structurées et facilement consultables.

CE QUE LE SYSTÈME DOIT FAIRE

Objectifs & solution



— Chapitres < 5 min

— Narration pédagogique

— Voix synthétique

— Scènes et schémas animés

— Sous-titres synchronisés

— Évaluation finale

— Publication web

— Pipeline automatisé et
reprenable

Diagramme de cas d'utilisation

QUI FAIT QUOI

Producteur de cours

Le service formation : il dépose le PDF, lance la production et suit les neuf étages.

Apprenant

Il consulte le catalogue, lit les vidéos, active les sous-titres, annote et passe l'évaluation.

Trois acteurs externes

Le modèle de rédaction, la synthèse vocale et le service d'images d'ambiance.

Deux usages distincts : produire le cours, puis l'apprendre.




Diagramme de classes

LE MODÈLE DE DONNÉES

Production

La racine : un identifiant, un état, le dernier étage validé et un dossier. C'est elle qui rend la reprise possible.

Cours → Chapitre → Séquence

La hiérarchie du contenu. Un chapitre porte son résumé, ses points clés, sa narration, son audio et ses sous-titres.

EtatEtage

Neuf instances, une par étage : son statut et les artefacts qu'il a écrits.

Les compositions traduisent la règle : effacer une production efface tout ce qu'elle contient.




Diagramme d'activité

LE DÉROULEMENT D'UNE PRODUCTION

Contrôle au dépôt

Un PDF sans couche texte ou un quiz mal formé est refusé immédiatement, pas au bout d'une heure.


Reprise

Si une production a été interrompue, la chaîne relit le dernier étage validé et repart au suivant.

Échec bloquant

Les artefacts déjà acquis sont conservés et l'arrêt est signalé — rien n'est perdu.

La boucle centrale exécute les neuf étages, un par un.





Conception du pipeline

Chaque étape lit et écrit des fichiers intermédiaires.

- Pipeline modulaire
- Reprenable après interruption
- Reproductible
- Chaque étape contrôlable

Le studio — la chaîne se lance depuis le navigateur, sans terminal.



Lecture du PDF

CE QU'ELLE FAIT

- Extraire le texte de chaque page
- Rendre chaque page en image, à 110 points par pouce
- Repérer les pages qui n'annoncent qu'un titre de partie
- Grouper les pages en chapitres de tailles comparables

CE QU'ELLE PRODUIT

Une description par page :
texte, image, position

TECHNOLOGIE

PyMuPDF

À RETENIR

Le nombre de chapitres découle du volume du support — ce n'est pas un paramètre que l'on saisit.

Génération de la narration

CE QU'ELLE FAIT

- Le modèle reçoit le texte et les images des pages
- Il produit titre, résumé, points clés et texte à prononcer
- Il développe le support sans y ajouter aucun fait
- Aucune donnée chiffrée ne doit disparaître

CE QU'ELLE PRODUIT

Les chapitres rédigés :
titre, résumé, points clés, narration

TECHNOLOGIE

Gemini + Pydantic

À RETENIR

La réponse est contrainte par un schéma déclaré, et la température est fixée à zéro : deux exécutions donnent le même texte.

Découpage en scènes

CE QU'ELLE FAIT

- La narration est coupée en scènes d'une dizaine de secondes
- Chaque scène reçoit un extrait contigu du texte
- Le texte n'est jamais réécrit en découpant
- Les scènes trop courtes sont fusionnées avec leur voisine

CE QU'ELLE PRODUIT

Le storyboard :
une liste de scènes et leur extrait

TECHNOLOGIE

Gemini

À RETENIR

Un contrôle vérifie que la concaténation des extraits redonne exactement la narration d'origine.

Synthèse vocale

CE QU'ELLE FAIT

- Chaque scène reçoit sa voix, en français
- Le moteur renvoie la position de chaque phrase prononcée
- La durée de la scène est mesurée sur l'audio produit
- Jamais estimée à partir d'un nombre de mots

CE QU'ELLE PRODUIT

L'audio de chaque scène,
et les repères de phrase

TECHNOLOGIE

edge-tts

À RETENIR

C'est cette mesure qui fixe la durée des scènes vidéo et le calage des sous-titres.

Génération des sous-titres

CE QU'ELLE FAIT

- Les repères de phrase deviennent des sous-titres horodatés
- Chacun est calé sur le moment où la voix le prononce
- Une piste par chapitre
- Activable à la lecture, et réutilisable autrement

CE QU'ELLE PRODUIT

Une piste de sous-titres
par chapitre

TECHNOLOGIE

Format WebVTT

À RETENIR

La même piste sert de transcription cliquable dans la plateforme : un seul fichier, deux usages.

Plan visuel

CE QU'ELLE FAIT

- Pour chaque scène, le modèle choisit une forme de schéma
- Dans un répertoire fermé de vingt-quatre archétypes
- Il en rédige les libellés et la phrase à retenir
- Deux scènes voisines ne portent pas la même forme

CE QU'ELLE PRODUIT

Le plan visuel :
archétype, libellés, phrase clé

TECHNOLOGIE

Gemini

À RETENIR

Les archétypes décrivent une structure de raisonnement — une inclusion, une progression, une comparaison — jamais un domaine.

Création des visuels

CE QU'ELLE FAIT

- Un arrière-plan d'ambiance est produit pour chaque scène
- Il est assombri et flouté derrière le schéma
- Il ne porte aucune information
- Si le service échoue, la scène s'affiche sur un dégradé

CE QU'ELLE PRODUIT

Un arrière-plan
par scène

TECHNOLOGIE

Modèle de diffusion

À RETENIR

Le rôle est délibérément décoratif : son absence dégrade le résultat proprement, elle ne l'interrompt pas.

Rendu vidéo

CE QU'ELLE FAIT

- Chaque scène est un composant rendu image par image
- Un navigateur sans interface dessine chaque image
- La durée vient de l'audio mesuré à l'étape 4
- L'image et le son ne peuvent pas dériver

CE QU'ELLE PRODUIT

Une vidéo
par chapitre

TECHNOLOGIE

Remotion + FFmpeg

À RETENIR

Le rendu est déterministe, et ne demande aucune carte graphique — c'était une contrainte du cahier des charges.

Publication

CE QU'ELLE FAIT

- L'évaluation est établie à partir du quiz officiel
- Reprise mot pour mot, parce qu'elle fait autorité
- Vidéos, sous-titres, quiz et métadonnées sont écrits
- Le catalogue de la plateforme est mis à jour

CE QU'ELLE PRODUIT

Un cours consultable
dans la plateforme

TECHNOLOGIE

Export web

À RETENIR

Aucune intervention manuelle entre la fin du rendu et la mise en ligne du cours.

LES OUTILS, GROUPÉS PAR RÔLE

Technologies utilisées

DOCUMENTS & DONNÉES

Py

PyMuPDF

Lecture du PDF

dx

python-docx

Quiz Word officiel



Pydantic

Formes validées

IA & SYNTHÈSE VOCALE



Gemini

Rédaction, multimodal

tts

edge-tts

Voix française

BACK-END & STUDIO



Python

Le pipeline entier



FastAPI

API et studio web

FRONT-END & VIDÉO

Re

Remotion

Scènes animées



React

Composants de scène



TypeScript

Scènes typées



FFmpeg

Assemblage et encodage

Aucune carte graphique requise.

C'était une contrainte du cahier des charges.



pytest

31 tests automatisés



Git

Versionnement du projet

UNE PRODUCTION AUTOMATISÉE

Résultats

28
pages



8
chapitres



17 min
de cours



68
scènes animées



110
sous-titres



8
questions

Support PDF


Cours vidéo

Plateforme e-learning

Chapitre le plus long : 3 min 15 s

l'exigence était de rester sous cinq minutes

Emplacement réservé — démonstration vidéo



CE QUI A ÉTÉ VÉRIFIÉ

Tests & validation

31

tests automatisés

TESTS AUTOMATISÉS

- pipeline
- données
- reprise
- cohérence

VALIDATION DU PRODUIT

- vidéo
- audio
- sous-titres
- visuels
- durée

7 / 8

objectifs entièrement atteints

7 / 8

valeurs chiffrées reprises

1 valeur chiffrée sur 8 n'a pas été reprise.

Un axe d'amélioration identifié.

Conclusion & perspectives

CE QUI A ÉTÉ RÉALISÉ

- Génération automatique du cours
- Chapitres courts
- Narration et voix synthétique
- Visuels et animations
- Sous-titres synchronisés
- Quiz final
- Publication web
- Pipeline reproductible et reprenable

PERSPECTIVES

- Améliorer l'exhaustivité des informations
- Étendre les types de contenus supportés
- Enrichir les modèles de schémas
- Développer le suivi des apprenants
- Passage à une utilisation de production

*Du support de formation au cours e-learning :
une chaîne de production automatisée par IA.*

Merci pour votre attention.