

Script et questions techniques

Du support de formation à l'e-learning, par intelligence artificielle

Hala Sadoumi · 4^e année Intelligence Artificielle & Data Science · EMSI

Document d'accompagnement de S2M_Soutenance.pptx — 22 diapositives, 600 secondes.

Avant de commencer

- Dix minutes, vingt-deux diapositives. Les durées portées dans ce document sont celles des notes de la présentation : leur somme fait exactement six cents secondes.
- Ouvrez le .pptx en mode Présentateur : les notes et le minuteur y sont. Le PDF ne sert que de secours, il ne contient pas les notes.
- Sur la diapositive des résultats, un emplacement est réservé à la démonstration vidéo. Ayez le fichier prêt en local — pas en ligne — et sachez quel chapitre vous montrez.
- Les deux cours déjà produits sont votre meilleur argument : « Sécurité SI » et « HSM et gestion de la cryptographie dans le milieu monétique ». Le second relève du cœur de métier de S2M et n'a demandé aucune modification du code.
- Une phrase à ne pas improviser : celle de la valeur chiffrée manquante. Dites-la vous-même, avant qu'on vous la demande. Elle vous sert.

Ce qu'il faut dire, diapositive par diapositive

Le texte ci-dessous est écrit pour être dit, non lu : phrases courtes, chiffres énoncés en toutes lettres. Les lignes en italique sont les transitions — ce sont elles qui évitent le silence entre deux diapositives.

Diapositive 1 • Couverture 20 s

Bonjour. Je m'appelle Hala Sadoumi, je suis en quatrième année intelligence artificielle et data science à l'EMSI, et j'ai effectué mon stage de fin d'études chez S2M Casablanca, au département des ressources humaines.

Le projet tient en trois mots : un support de formation en PDF, une chaîne d'intelligence artificielle, un cours e-learning complet.

→ *Voici le chemin que je vous propose.*

Diapositive 2 • Plan de la présentation 15 s

Je commence par le contexte et la problématique, puis je présente brièvement S2M et le département qui m'a accueillie.

Je passe ensuite aux objectifs et à la solution retenue, à la conception — les diagrammes et le pipeline —, puis au fonctionnement étape par étape. Je termine par les technologies, les résultats et les perspectives.

→ *Commençons par le point de départ.*

Diapositive 3 • Contexte & problématique 55 s

Une entreprise comme S2M produit régulièrement des supports de formation. Les transformer en cours e-learning suppose de les analyser, de les scénariser, d'enregistrer une voix, de monter, de sous-titrer, puis de publier.

Chaque étape est manuelle, et l'ensemble se compte en jours par formation. Sur un catalogue entier, l'effort devient prohibitif — et surtout, le résultat est difficile à reproduire à l'identique d'un support à l'autre.

La question qui a guidé tout le projet est donc celle-ci : comment automatiser cette transformation de bout en bout, sans perdre la qualité pédagogique ?

Je précise tout de suite le déplacement du problème : la difficulté n'est pas de diffuser un cours — les plateformes savent le faire. La difficulté est de le produire.

→ *Un mot sur l'entreprise qui m'a accueillie.*

Diapositive 4 • S2M Casablanca 35 s

S2M est une entreprise marocaine spécialisée dans la monétique. Elle édite des solutions logicielles de paiement, fournit les moyens de paiement physiques — cartes et terminaux — et exploite ces systèmes pour ses clients en mode service. Sa présence est internationale : Maroc, Afrique, Moyen-Orient, Asie et Océanie.

Mon stage s'est déroulé aux ressources humaines, sur le volet formation. Ce rattachement compte : le commanditaire n'était pas une équipe technique, mais le service qui doit rendre ses formations accessibles et consultables.

→ *Voyons ce que le système devait faire.*

Diapositive 5 • Objectifs & solution 45 s

La solution tient en une transformation. En entrée, le support PDF existant. Au centre, une chaîne d'intelligence artificielle qui comprend le document, rédige le contenu et le structure. En sortie, un cours e-learning complet.

Autour de ce flux, les huit objectifs du cahier des charges : des chapitres de moins de cinq minutes, une narration pédagogique et non un résumé, une voix de synthèse, des scènes et des schémas animés, des sous-titres calés sur la parole, une évaluation finale, la publication web — et une chaîne automatisée et reprenable.

→ *Passons à la conception. Quatre diagrammes, quatre questions différentes.*

Diapositive 6 • Diagramme de cas d'utilisation 20 s

Le diagramme de cas d'utilisation fixe les frontières du système. Deux acteurs humains : le producteur de cours, c'est-à-dire le service formation, qui dépose le support et lance la production ; et l'apprenant, qui consulte le catalogue, lit les vidéos, active les sous-titres et passe l'évaluation.

À gauche, trois acteurs externes que le système appelle sans les posséder : le modèle de rédaction, la synthèse vocale et le service d'images. Ce qu'il faut retenir : il y a deux usages bien séparés — produire le cours, puis l'apprendre.

→ *Voyons maintenant ce que le système manipule.*

Diapositive 7 • Diagramme de classes 20 s

Le diagramme de classes décrit les données. La racine est la Production : elle porte son état et le dernier étage validé — et c'est précisément ce qui permet de reprendre une production interrompue au lieu de tout recommencer.

En dessous, la hiérarchie du contenu : un cours contient des chapitres, un chapitre contient des séquences, et chaque séquence porte son schéma animé et son arrière-plan. À droite, les neuf états d'étage. Les losanges pleins sont des compositions : supprimer une production supprime tout ce qu'elle contient.

→ *Et voici comment tout cela s'enchaîne dans le temps.*

Diapositive 8 • Diagramme d'activité 20 s

À gauche, le dépôt : on contrôle que le PDF a bien une couche texte et que le quiz est lisible, et on refuse tout de suite si ce n'est pas le cas. C'était un défaut du premier prototype, qui échouait après une heure et demie de traitement ; le contrôle a été remonté au dépôt.

À droite, la boucle : si une production a été interrompue, on relit le dernier étage validé et on repart au suivant, sinon on démarre à l'étage un. Chaque étage écrit ses artefacts et son état. En cas d'échec bloquant, ce qui a été acquis est conservé.

→ *Voici enfin l'enchaînement complet du pipeline.*

Diapositive 9 • Conception du pipeline 30 s

Neuf étapes, de la lecture du support jusqu'à la publication, et sur chaque flèche ce qui circule : les unités de contenu, les narrations, les phrases et leurs repères temporels, les schémas animés, les arrière-plans.

Le principe qui tient tout l'ensemble est simple : chaque étape lit des fichiers et en écrit d'autres, rien n'est gardé en mémoire. De là viennent les quatre propriétés — la chaîne est modulaire, reproductible, elle reprend après une interruption, et chaque étape se contrôle indépendamment.

Les deux notes jaunes sont des contraintes du cahier des charges : le repli au fond uni si le service d'images est indisponible, et une seule production rendue à la fois. En bas à gauche, le studio : c'est de là que la production se lance, sans terminal.

→ *Je vais maintenant reprendre ces neuf étapes une par une.*

Les neuf étapes • diapositives 10 à 18

Neuf diapositives de dix-huit secondes chacune : une phrase de cadrage, le point technique, la phrase à retenir. Ne vous attardez pas — le détail se dit en questions.

Diapositive 10 · Étape 1 — Lecture du PDF 18 s

Première étape : lire le support. Le texte seul ne suffit pas — sur le support de validation, quatre diapositives portaient leurs chiffres dans des graphiques. Chaque page est donc aussi rendue en image, et les deux sont fournis au modèle.

À retenir : le nombre de chapitres découle du volume du support. Ce n'est pas un paramètre que l'on saisit.

Diapositive 11 · Étape 2 — Génération de la narration 18 s

C'est l'étape qui décide de la valeur pédagogique. Une diapositive porte des mots-clés ; la narration doit en faire un enseignement. Sur le support traité, mille quatre cent cinq mots de source sont devenus deux mille six cent vingt-cinq mots de narration.

La réponse est contrainte par un schéma déclaré et la température est fixée à zéro.

Diapositive 12 · Étape 3 — Découpage en scènes 18 s

Une narration de trois cents mots ne peut pas être portée par une seule image fixe. Le point délicat est que le modèle découpe sans réécrire : si le texte changeait ici, la voix ne correspondrait plus à ce qui a été validé.

D'où le contrôle : la concaténation des extraits doit redonner exactement la narration d'origine.

Diapositive 13 · Étape 4 — Synthèse vocale 18 s

Le moteur de voix a été retenu pour une propriété rarement mise en avant : il renvoie, pour chaque phrase, l'instant où elle commence et celui où elle finit.

Ces repères servent deux fois — ils donnent la durée exacte de chaque scène, et ils calent les sous-titres sur la parole réelle. Aucune des deux valeurs n'est estimée.

Diapositive 14 · Étape 5 — Génération des sous-titres 18 s

Les sous-titres remplissent une fonction d'accessibilité qui dépasse le confort : un collaborateur sourd, ou en environnement bruyant, ne suit le cours que par eux.

Et comme ils sont calés sur la parole réelle, il n'y a pas de dérive au fil du chapitre. La même piste sert de transcription cliquable : un fichier, deux usages.

Diapositive 15 · Étape 6 — Plan visuel 18 s

C'est le choix de conception le plus caractéristique du système. Le modèle ne dessine pas et ne décrit pas librement une image : il choisit une forme dans une liste fermée.

Les archétypes décrivent une structure de raisonnement — une inclusion, une progression, une comparaison — jamais un domaine. C'est cette ignorance délibérée du sujet qui permet de traiter n'importe quel support.

Diapositive 16 · Étape 7 — Création des visuels 18 s

Un modèle de diffusion ne produit pas de texte lisible : il génère des formes qui ressemblent à des lettres sans en être. Toute information portée par une image générée serait donc illisible.

C'est pourquoi les schémas sont dessinés par du code, et pourquoi ces images restent cantonnées à l'ambiance. Leur absence dégrade le résultat proprement, elle ne l'interrompt pas.

Diapositive 17 · Étape 8 — Rendu vidéo 18 s

C'est l'étape la plus longue : elle occupe l'essentiel du temps machine, environ une heure et demie.

La vidéo n'est pas montée, elle est programmée : chaque scène est un composant React dont l'image dépend du seul numéro d'image. C'est ce qui la rend reproductible, et elle ne demande aucune carte graphique.

Diapositive 18 · Étape 9 — Publication 18 s

La dernière étape écrit, dans le dossier que la plateforme relit au chargement, tout ce dont un apprenant a besoin : les vidéos, les pistes de sous-titres, le quiz, une vignette et le support d'origine téléchargeable.

Le quiz officiel des formateurs est repris tel quel plutôt que généré : il reflète ce que les auteurs veulent réellement vérifier. Aucune intervention manuelle entre la fin du rendu et la mise en ligne.

→ *Un mot sur les outils qui portent tout cela.*

Diapositive 19 · Technologies utilisées 45 s

Les outils, par rôle. Pour les documents : PyMuPDF lit le PDF — il extrait le texte et rend la page en image avec la même bibliothèque ; python-docx lit le quiz officiel ; et Pydantic déclare la forme attendue de chaque réponse du modèle. Cette déclaration sert deux fois : elle contraint le modèle et valide sa sortie.

Pour l'intelligence artificielle : Gemini, multimodal, ce qui lui permet de lire un graphique ; et edge-tts pour la voix française.

Pour le back-end : Python porte toute la chaîne, FastAPI porte le studio. Pour le front-end et la vidéo : Remotion, React et TypeScript pour les scènes animées, FFmpeg pour l'assemblage.

Un point important : rien de tout cela ne demande de carte graphique, ce qui était une contrainte du cahier des charges.

→ *Voyons ce que le système produit réellement.*

Diapositive 20 • Résultats 48 s

Voici ce que le système produit sur le support de validation. Vingt-huit pages en entrée donnent huit chapitres, dix-sept minutes de cours, soixante-huit scènes animées, cent dix sous-titres et huit questions d'évaluation.

Le chapitre le plus long fait trois minutes quinze, pour une exigence fixée à cinq minutes : l'objectif est tenu avec de la marge.

À droite, six scènes du cours produit. J'attire votre attention sur un point : aucune n'est une capture du PDF. Tout est redessiné.

→ *Parlons maintenant de la validation.*

Diapositive 21 • Tests & validation 45 s

La validation s'est faite à deux niveaux. D'abord des tests automatisés, qui couvrent les fonctions qui décident : le pipeline, le traitement des données, la reprise après interruption, la cohérence des résultats.

Mais un système qui fabrique du contenu ne se valide pas uniquement par des tests sur son code. Il a fallu regarder la vidéo, écouter l'audio, vérifier les sous-titres, les visuels et les durées.

Résultat : sept objectifs sur huit entièrement atteints, et sept valeurs chiffrées sur huit reprises. Une valeur manque. Je le dis clairement parce que c'est un axe d'amélioration identifié, et non un résultat que je cherche à masquer.

→ *Pour conclure.*

Diapositive 22 • Conclusion & perspectives 40 s

Le système génère automatiquement un cours complet à partir d'un support PDF : des chapitres courts, une narration portée par une voix de synthèse, des visuels animés, des sous-titres, un quiz final et la publication web — le tout par une chaîne reproductible et repreneable.

Les perspectives sont claires : améliorer l'exhaustivité des informations reprises, étendre les types de contenus acceptés, enrichir les modèles de schémas, développer le suivi des apprenants, et passer à une utilisation de production.

Je vous remercie de votre attention.

Les questions techniques, et quoi répondre

Les réponses sont rédigées pour être dites en trente à soixante secondes. Le premier paragraphe répond ; les suivants servent si l'on vous relance. Chaque chiffre cité ici a été vérifié dans le code du projet.

A — Le choix de l'IA et son encadrement

Quel modèle avez-vous utilisé, et pourquoi deux ?

Deux modèles Gemini, pour deux usages. Un modèle allégé traite les tâches mécaniques — découpage en scènes, plan visuel, quiz — et dispose d'un quota généreux. Un modèle complet est réservé à la rédaction de la narration : l'allégé perdait régulièrement les accents et écrivait une prose plate. La rédaction ne coûte qu'un appel par chapitre, ce qui tient dans son quota plus étroit.

Le choix du modèle est une variable d'environnement : en changer ne demande pas de toucher au code.

Comment empêchez-vous le modèle d'halluciner ?

Trois garde-fous, à trois niveaux.

D'abord, le modèle ne répond jamais en texte libre : chaque appel déclare un schéma Pydantic, et la réponse est validée contre ce schéma. Une réponse mal formée est rejetée avant d'entrer dans la chaîne.

Ensuite, la température est forcée à zéro, au niveau du client et non de chaque appel — pour qu'un oubli à un endroit ne rouvre pas la porte.

Enfin, un contrôle de conservation à l'étape trois : la concaténation des extraits de scènes doit redonner exactement la narration de l'étape deux. Si le modèle a réécrit au lieu de découper, c'est détecté.

Et il faut rappeler le cadre : le modèle n'invente pas un sujet, il reformule un support qu'on lui fournit. Ce n'est pas de la génération libre.

Deux exécutions donnent-elles exactement le même cours ?

En pratique, oui : température zéro et schéma contraint. Mais je préfère être précise — un fournisseur ne garantit pas une sortie identique au bit près même à température zéro, parce que l'inférence tourne sur une infrastructure distribuée.

La reproductibilité forte du système est ailleurs : les artefacts intermédiaires sont écrits sur disque. Rejouer une étape à partir des mêmes fichiers donne le même résultat, et le rendu vidéo, lui, est déterministe.

Pourquoi ne pas avoir fait un fine-tuning ?

Parce que le besoin n'est pas d'apprendre un domaine. S2M produit des supports sur des sujets variés — sécurité des systèmes d'information, cryptographie monétique. Un modèle affiné sur un corpus donné serait moins bon sur le support suivant.

Et un fine-tuning suppose un jeu de données annoté qui n'existait pas, du temps de calcul, et une nouvelle itération à chaque domaine. Le prompt encadré par un schéma rend le même service sans cette dette.

Pourquoi pas du RAG ?

Le RAG sert à retrouver l'information pertinente dans un grand corpus. Ici le corpus est un seul document d'une trentaine de pages, fourni en entier au modèle : il n'y a rien à retrouver.

Le RAG deviendrait pertinent si l'on voulait croiser plusieurs supports, ou s'appuyer sur une base documentaire d'entreprise. C'est une piste, pas un manque.

Le modèle voit-il vraiment les images du support ?

Oui, et c'est décisif. Sur le support de validation, quatre diapositives portaient leurs chiffres dans des graphiques — invisibles dans la couche texte. Chaque page est donc rendue en image à cent dix points par pouce et fournie au modèle en plus du texte.

C'est le seul usage de la multimodalité dans le projet, mais sans lui une partie de l'information serait perdue.

Combien d'appels au modèle pour produire un cours ?

Trois étapes sur neuf appellent le modèle : la rédaction de la narration, le découpage en scènes et le plan visuel. Les six autres sont du code déterministe.

Le volume reste de l'ordre de quelques dizaines d'appels pour un cours entier — un appel de rédaction par chapitre, puis des appels de découpage et de plan visuel. Ce n'est pas un système qui interroge le modèle en boucle.

Et si le service d'IA est indisponible ?

Les erreurs transitoires sont réessayées automatiquement, avec une attente qui croît à chaque tentative. Si l'échec persiste, l'étape s'arrête, conserve ses artefacts et le signale.

La production reprend plus tard au même point, sans refaire les étages précédents. C'est exactement ce que montre le diagramme d'activité.

Pourquoi Gemini plutôt qu'un autre fournisseur ?

Trois raisons. Le multimodal natif, qui permet de lui donner la page rendue en image. La sortie structurée native, qui évite un post-traitement fragile du texte. Et un quota gratuit suffisant pour un projet de stage.

Le point important est que ce choix est isolé dans un seul module. Changer de fournisseur ne touche pas le reste de la chaîne — c'est une décision réversible.

B — Lecture du support et découpage

Comment décidez-vous du nombre de chapitres ?

On ne le décide pas : il découle du volume du support. La cible est exprimée en mots du support — environ cent quatre-vingt-dix mots par chapitre, avec un plancher — et non en nombre de chapitres.

Conséquence : un document deux fois plus long donne deux fois plus de chapitres, et rien n'est réglé pour un document particulier. Le cours Sécurité SI a donné huit chapitres, le cours HSM neuf.

Comment reconnaissez-vous une page de séparation ?

Par une règle qui ne présuppose rien du sujet : moins de soixante-dix caractères et plus de quatre-vingts pour cent de capitales. C'est le motif typographique d'un titre de partie, pas un mot-clé métier.

C'est la même logique que pour les archétypes visuels : décrire une forme, jamais un domaine.

Que se passe-t-il avec un PDF scanné ?

Il est refusé au dépôt, immédiatement, avec l'indication de la forme attendue. Le système exige une couche texte.

C'était justement un défaut du premier prototype : il acceptait le fichier et échouait après une heure et demie de traitement. Le contrôle a été remonté au dépôt.

Pourquoi ne pas avoir ajouté de l'OCR ?

C'était un arbitrage de périmètre. Les supports de S2M sont produits sous PowerPoint puis exportés : ils ont tous une couche texte. Ajouter l'OCR aurait ajouté une dépendance et une source d'erreur pour un cas qui ne se présente pas.

C'est une extension naturelle si le besoin apparaît, et elle se brancherait sur la première étape sans toucher aux huit autres.

Pourquoi cent dix points par pouce pour le rendu des pages ?

C'est un compromis entre la lisibilité pour le modèle et le poids des images envoyées. À cette résolution, une diapositive reste lisible, y compris les libellés d'un graphique, sans faire enfler la requête.

Comment garantisiez-vous qu'un chapitre dure moins de cinq minutes ?

Pas par estimation. Le plafond — trois cents secondes — est contrôlé une fois la voix synthétisée et sa durée réelle connue.

Sur le cours de validation, le chapitre le plus long fait trois minutes quinze. L'objectif est tenu avec de la marge.

C — Voix, sous-titres et langues

Pourquoi ce moteur de synthèse vocale ?

Pour une propriété rarement mise en avant : il renvoie, pour chaque phrase, l'instant où elle commence et celui où elle finit.

Ces repères servent deux fois — ils fixent la durée exacte de chaque scène vidéo, et ils calent les sous-titres sur la parole réelle. Aucune des deux valeurs n'est estimée. C'est ce qui évite la dérive progressive qu'on voit souvent sur les sous-titres générés.

Quelle est la limite de ce choix ?

Le service est gratuit et ne demande pas de clé, mais il n'est pas contractuel. Pour une exploitation de production, il faudrait le remplacer par un service sous contrat, avec un engagement de disponibilité.

Le module audio est isolé : la substitution est locale, elle ne remet pas en cause l'architecture.

Les sous-titres sont-ils produits par reconnaissance vocale ?

Non, et c'est mieux ainsi : on connaît déjà le texte prononcé, puisque c'est nous qui l'avons fait dire. Passer par une reconnaissance introduirait des erreurs là où on possède la vérité.

Les sous-titres sont le texte de la narration, découpé et calé sur les repères temporels du moteur. Le format est WebVTT, une piste par chapitre, et le même fichier sert de transcription cliquable dans la plateforme.

Le cours peut-il être dans une autre langue ?

La chaîne sait produire une seconde piste de sous-titres traduite — les pistes traduites portent un suffixe de langue, et le décompte des chapitres les exclut, ce qui a d'ailleurs fait l'objet d'un test dédié.

La narration audio, elle, est en français. Un support en anglais demanderait une voix anglaise et des consignes adaptées ; l'architecture ne s'y oppose pas.

D — Visuels et rendu vidéo

Les schémas sont-ils générés par une IA d'image ?

Non, et c'est un choix central du projet. Un modèle de diffusion ne produit pas de texte lisible : il génère des formes qui ressemblent à des lettres sans en être. Toute information portée par une image générée serait donc illisible.

Les schémas sont dessinés par du code — des composants React. L'IA ne choisit que la forme du raisonnement et les libellés.

Comment le modèle choisit-il la forme d'un schéma ?

Dans un vocabulaire fermé de vingt-quatre archétypes, chacun adossé à un composant. Les archétypes décrivent une structure de raisonnement — une inclusion, une progression, une comparaison, une répartition, un classement — jamais un domaine.

Cette ignorance délibérée du sujet est ce qui permet de traiter n'importe quel support sans réécrire le système. Sur les soixante-huit scènes du cours de validation, dix-sept formes distinctes ont été employées.

Le rendu ne devient-il pas répétitif ?

Une règle de variété l'évite : si un archétype vient d'être utilisé, le système cherche une alternative parmi les formes compatibles avec le même contenu. Ce n'est pas un tirage au hasard — les formes candidates doivent pouvoir porter la même information.

À quoi servent les images d'ambiance, alors ?

À rien d'informatif, volontairement. Leur rôle est décoratif, et leur absence dégrade le résultat proprement — repli sur un fond uni — sans interrompre la production.

C'était une contrainte explicite du cahier des charges : un service externe optionnel ne doit jamais bloquer la chaîne.

Pourquoi Remotion plutôt qu'un outil de montage ?

Parce que la vidéo n'est pas montée, elle est programmée : chaque scène est un composant React dont l'image affichée dépend du seul numéro d'image. C'est ce qui la rend reproductible.

C'est aussi ce qui permet d'animer un schéma vectoriel proprement — une barre qui monte, une liste qui se coche — ce qu'un assemblage d'images fixes ne fait pas. Le format de sortie est 1920 par 1080, à trente images par seconde.

Combien de temps pour produire un cours ?

Le rendu vidéo est l'étape la plus longue : environ une heure et demie pour les dix-sept minutes du cours de validation, sur un portable sans carte graphique. Le rendu utilise la moitié des cœurs disponibles, pour laisser la machine utilisable.

Les autres étapes se comptent en minutes.

Pourquoi aucune carte graphique n'est-elle nécessaire ?

C'était une contrainte du cahier des charges : le système devait tourner sur le poste existant. Et aucune étape n'en demande — la voix est un service distant, les schémas sont rendus par un navigateur, et l'encodage est fait par FFmpeg en logiciel.

E — Architecture, reprise et fiabilité

Pourquoi une chaîne de fichiers plutôt qu'un traitement en mémoire ?

Parce que c'est ce qui donne les quatre propriétés d'un seul coup. Chaque étape lit des fichiers et en écrit d'autres : on peut donc rejouer une étape seule, inspecter son résultat, reprendre après une interruption, et remplacer une étape sans toucher aux autres.

Sur une chaîne d'une heure et demie, une panne au huitième étage ne doit pas coûter les sept premiers. C'est le raisonnement qui a fixé l'architecture.

Où est stocké l'état d'avancement ?

Sur disque — mais surtout, il est déduit des artefacts présents. Un étage est terminé quand son résultat est là.

La chaîne étant strictement séquentielle, le premier étage sans résultat est celui en cours : il n'y a pas d'ambiguïté possible, et pas d'état à maintenir en double. C'est un état qui ne peut pas mentir, puisqu'il est lu depuis ce qui existe réellement.

Pourquoi pas de base de données ?

Parce qu'il n'y en a pas besoin : un cours est un dossier de fichiers, et la plateforme relit un catalogue au chargement. Une base aurait ajouté un composant à installer, sauvegarder et migrer, pour stocker ce que le système de fichiers stocke déjà.

C'est une décision réversible : l'export web est un module isolé. Si l'intégration chez S2M impose une base, c'est ce module-là qui change.

Peut-on lancer plusieurs productions en parallèle ?

Non, une seule à la fois — et c'est explicite dans le cahier des charges. Le rendu vidéo sature déjà la machine ; deux rendus concurrents se ralentiraient mutuellement sans rien gagner.

Ce n'est pas une limite de conception mais un arbitrage : la file d'attente est plus simple à raisonner que la concurrence, pour un besoin qui ne réclame pas le parallélisme.

Qu'est-ce que le studio, exactement ?

Une interface web servie par FastAPI, qui permet de déposer un support, de lancer une production et de suivre les neuf étages sans ouvrir de terminal.

C'est ce qui rend l'outil utilisable par le service formation, et non seulement par un développeur. Sans lui, le projet serait un script — pas un outil.

F — Tests et validation

Que testez-vous exactement ?

Les fonctions qui décident, pas le contenu généré : le découpage des chapitres, la reprise après interruption, la cohérence du rapport d'avancement, le traitement des données, les cas limites de la publication.

Quelques intitulés donnent le ton : « un étage partiel ne bloque pas les suivants », « une publication sans un seul chapitre n'est pas un cours terminé », « une seconde langue de sous-titres n'est pas comptée comme des chapitres en plus ». Chaque test correspond à un défaut réellement rencontré.

Combien de tests, et passent-ils tous ?

Quarante tests aujourd'hui, tous au vert. Le rapport en cite trente et un — c'est le chiffre au moment de sa rédaction ; la suite a grandi depuis, au fil des défauts corrigés.

Comment teste-t-on un système qui fabrique du contenu ?

On ne le teste pas uniquement par des tests unitaires, et c'est un point que j'assume. Le code se teste ; le contenu se relit.

Il a donc fallu regarder la vidéo, écouter l'audio, vérifier les sous-titres, les visuels et les durées. La validation est à deux niveaux, et le second est humain.

Sur combien de supports le système a-t-il été validé ?

Deux, et ils sont volontairement différents. « Sécurité SI » : huit chapitres, dix-sept minutes, huit questions. Et « HSM et gestion de la cryptographie dans le milieu monétique » : neuf chapitres, vingt minutes, vingt-sept questions — un sujet qui relève du cœur de métier de S2M.

C'est ce qui démontre que le système n'est pas réglé pour un document particulier : le second support n'a demandé aucune modification du code.

Qu'est-ce qui n'a pas fonctionné ?

Une valeur chiffrée sur huit n'a pas été reprise dans la narration. Je le dis parce que c'est un axe d'amélioration identifié, pas un résultat que je cherche à masquer.

La piste est claire : renforcer la consigne de reprise exhaustive des chiffres à l'étape de rédaction, et ajouter un contrôle automatique qui compare les nombres présents dans le support à ceux présents dans la narration. Ce contrôle serait du même genre que celui qui vérifie déjà la conservation du texte au découpage.

Comment mesurez-vous la qualité pédagogique ?

Elle n'est pas mesurée par une métrique automatique, et c'est une limite honnête du travail. Elle a été évaluée par relecture, avec le service formation.

La mesure réelle serait un retour d'apprenants — taux d'achèvement, résultats au quiz — et cela suppose une mise en service. C'est d'ailleurs pourquoi le suivi des apprenants figure dans les perspectives.

G — Sécurité et confidentialité

Les supports de S2M sont envoyés à un service externe. N'est-ce pas un risque ?

C'est le point de vigilance du projet, et il doit être tranché par S2M avant toute mise en production. Trois éléments de réponse.

Premièrement, ce qui est envoyé, ce sont les pages d'un support de formation — pas des données de production, pas des données client, pas de flux monétique.

Deuxièmement, le choix du fournisseur est isolé dans un seul module : basculer vers un modèle hébergé en interne, ou vers un contrat d'entreprise avec garanties de non-réutilisation, ne touche pas le reste de la chaîne.

Troisièmement, pour un support classé sensible, le système ne doit pas être utilisé en l'état. C'est une règle d'usage à poser, pas un défaut technique à corriger.

Où est stockée la clé d'API ?

Dans une variable d'environnement, lue depuis un fichier de configuration qui n'est pas versionné. Aucun secret n'est écrit dans le code, et le dépôt ne contient qu'un exemple de configuration sans valeur réelle.

Et le RGPD, les données des apprenants ?

La chaîne de production ne collecte aucune donnée d'apprenant : elle fabrique un cours. La question se posera au moment du suivi des apprenants, qui est listé dans les perspectives — et elle se posera côté plateforme, pas côté chaîne de production.

H — Intégration et exploitation

Comment cela s'intègre-t-il à la plateforme de S2M ?

La chaîne écrit un dossier par cours et un catalogue que la plateforme relit. Le front-end que j'ai réalisé est une démonstration : si S2M dispose déjà d'une plateforme, c'est cette sortie-là qu'elle consomme, et mon front-end devient facultatif.

J'ai adressé par écrit au service la liste des questions nécessaires à l'intégration — format attendu, authentification, hébergement des vidéos, suivi des apprenants.

Pourquoi n'avez-vous pas produit de paquet SCORM ?

SCORM est le format d'échange standard des plateformes de formation. Le système ne le produit pas aujourd'hui, parce que la plateforme cible n'était pas arrêtée pendant le stage — et un paquet SCORM se conçoit pour une plateforme donnée.

Techniquement l'écart est faible : un cours est déjà un dossier de vidéos, de pistes de sous-titres et d'un quiz. SCORM ajoute un manifeste et une couche de dialogue avec la plateforme pour remonter la progression. C'est une évolution à chiffrer une fois la cible connue.

Qui fera tourner le système au quotidien ?

Le service formation, depuis le studio, sans ligne de commande. C'est précisément l'objet du studio — et c'est ce qui distingue un outil livrable d'un prototype de développeur.

Combien coûte la production d'un cours ?

Pendant le stage, les appels au modèle ont tenu dans les quotas gratuits, et la synthèse vocale est gratuite. Le coût réel est du temps machine : environ une heure et demie de rendu.

Je ne veux pas donner un chiffre d'exploitation que je ne peux pas tenir : un chiffrage sérieux suppose de retenir un fournisseur sous contrat, ce que le quota gratuit ne permet pas de projeter.

Pourra-t-on faire évoluer le code après l'intégration ?

Oui. Le projet est versionné sous Git, et la chaîne de production est séparée de la plateforme de diffusion. On peut faire évoluer l'une sans toucher à l'autre.

I — Limites et perspectives

Quelles sont les limites du système ?

Cinq, que j'énonce franchement. Il exige un PDF à couche texte. Une valeur chiffrée sur huit n'a pas été reprise. La qualité pédagogique n'est pas mesurée automatiquement. Le vocabulaire visuel est fermé à vingt-quatre formes. Et une seule production tourne à la fois.

Aucune de ces limites n'est un obstacle de conception : ce sont des arbitrages de périmètre, et chacune a une piste de levée identifiée.

Un vocabulaire visuel fermé, n'est-ce pas restrictif ?

C'est un arbitrage assumé. Une forme fermée garantit un rendu lisible et animable ; une forme libre donnerait des images illisibles — c'est exactement ce qu'on observe avec les modèles d'image.

Et l'élargir est un travail additif : un composant de plus, une entrée de vocabulaire de plus. Jamais une réécriture.

Quelle est la suite du projet ?

Cinq directions : améliorer l'exhaustivité des informations reprises, étendre les types de contenus acceptés au-delà du PDF, enrichir les modèles de schémas, développer le suivi des apprenants, et passer à une utilisation de production.

La première est la plus importante, parce qu'elle répond au seul objectif qui n'est pas entièrement atteint.

J — Méthodologie et gestion de projet

Comment le projet a-t-il été conduit ?

En sprints, avec un découpage par incréments livrables : chaque sprint se terminait par quelque chose qui tourne, pas par un document. Le rapport détaille le déroulement et le diagramme de Gantt.

Cette conduite se voit dans le produit : les contrôles remontés au dépôt, la reprise après interruption, le studio — ce sont des réponses à des problèmes rencontrés en cours de route, pas des exigences initiales.

Pourquoi ces trois diagrammes UML, et pas d'autres ?

Parce qu'ils répondent à trois questions différentes. Le cas d'utilisation dit qui fait quoi et où s'arrête le système. Le diagramme de classes dit ce qui est manipulé. Le diagramme d'activité dit dans quel ordre, et avec quels aléas.

Un diagramme de séquence aurait redit l'activité sans rien ajouter, puisque la chaîne est strictement séquentielle et qu'il n'y a pas de dialogue concurrent entre composants.

Qu'est-ce qui a été le plus difficile ?

Le passage du prototype à l'outil. Faire produire une vidéo une fois est un problème ; faire que la production soit reprenable, contrôlable et utilisable par quelqu'un d'autre que moi en est un autre — et c'est celui qui a demandé le plus de reprises.

À personnaliser : citez ici l'épisode qui vous a réellement coûté le plus — le contrôle du quiz remonté au dépôt, ou le mélange des voix entre deux cours.

K — Les questions qui déstabilisent

« Au fond, vous n'avez fait qu'appeler une API. »

Les appels au modèle représentent trois étapes sur neuf. Le travail est dans ce qui les entoure : contraindre les réponses par un schéma, vérifier qu'un découpage n'a pas réécrit le texte, caler des sous-titres sur des repères réels plutôt qu'estimés, traduire un choix d'archétype en une animation programmée, et rendre l'ensemble reprenable après une panne.

Une API seule ne produit pas dix-sept minutes de cours structuré et publié.

« Ces outils existent déjà. »

Oui, et ils répondent à un autre besoin : les générateurs de vidéo fabriquent une vidéo à partir d'un script qu'on leur fournit. Ici, l'entrée est un PDF — et c'est précisément la scénarisation, découper, rédiger, choisir une forme visuelle, qui est automatisée.

La seconde différence est l'intégration : la sortie est faite pour la plateforme de S2M, et le support d'origine reste téléchargeable à côté du cours.

« Quelle est votre contribution personnelle ? »

L'architecture en neuf étages reprenables. Le vocabulaire fermé d'archétypes visuels et son rendu programmé. Le calage des sous-titres sur les repères réels du moteur de voix. Les contrôles de conservation du texte. Le studio, qui rend l'outil utilisable sans terminal. Et la validation sur deux supports de nature différente.

Le modèle de langage est un composant du système, pas le système.

« Et si le modèle écrit une bêtise pédagogique ? »

C'est possible, et c'est pour cela que la relecture humaine reste dans la boucle avant publication. Le système produit un cours prêt à relire, pas un cours au-dessus de tout soupçon.

Ce qu'il garantit, c'est la forme : des chapitres courts, une narration cohérente avec l'audio, des sous-titres calés, un quiz qui vient des formateurs. Le fond reste sous la responsabilité du service formation — c'est d'ailleurs pourquoi le quiz officiel est repris tel quel plutôt que généré.

Et si vous ne savez pas répondre ?

Dites-le, puis ramenez la question à ce que vous savez. Par exemple : « Je n'ai pas mesuré ce point précis. Ce que je peux dire, c'est que... ». Un jury sanctionne une réponse inventée, jamais une limite assumée — et vous avez déjà démontré cette honnêteté en présentant la valeur chiffrée manquante.